

TRABAJO PRÁCTICO — APLICACIÓN DE UN MODELO DE MACHINE LEARNING

Objetivo

A partir del dataset seleccionado y preparado en el trabajo anterior de **EDA y limpieza de datos**, deberán plantear un problema de Machine Learning y aplicar un algoritmo de los trabajados en clase.

El objetivo es comprender y aplicar las principales etapas de construcción de un modelo:

Plantear el problema → seleccionar las variables → elegir el algoritmo → entrenar → probar → analizar los resultados.

1. Planteamiento del problema

Cada grupo deberá definir **qué problema quiere resolver utilizando su dataset**.

Deberán formular una pregunta concreta que pueda ser abordada mediante Machine Learning.

Por ejemplo:

Clasificación

¿Podemos predecir si una obra pertenece a determinada categoría?

Regresión

¿Podemos predecir el costo de una obra a partir de sus características?

Agrupación

¿Podemos encontrar grupos de obras con características similares?

La pregunta deberá estar relacionada con el dataset que el grupo seleccionó y preparó en el trabajo anterior.

2. Identificar el tipo de aprendizaje

Deberán indicar qué tipo de Machine Learning corresponde al problema planteado:

Aprendizaje supervisado

Se utiliza cuando conocemos la variable que queremos predecir.

Puede tratarse de:

- **Clasificación:** predecir una categoría.
- **Regresión:** predecir un valor numérico.

Aprendizaje no supervisado

Se utiliza cuando no tenemos una categoría o respuesta previamente definida y buscamos encontrar estructuras o grupos dentro de los datos.

En clase trabajamos:

- K-Means
- DBSCAN
- Agrupación Aglomerativa.

3. Selección de variables

Deberán identificar las variables que utilizarán para el modelo.

Para clasificación o regresión

Deberán indicar:

Variable objetivo (Y):

Es aquello que queremos predecir.

Variables de entrada (X):

Son las características que utilizaremos para realizar la predicción.

Por ejemplo:

Objetivo: predecir el costo real de una obra.

Y = Costo real

X = superficie, presupuesto, duración, trabajadores, etc.

Deberán explicar brevemente por qué seleccionaron esas variables.

Para clustering

No tendrán una variable objetivo.

Deberán seleccionar las variables que utilizarán para encontrar los grupos y explicar por qué las consideran relevantes.

4. Selección del algoritmo

Deberán elegir **uno de los algoritmos trabajados en clase**, de acuerdo con el problema planteado.

Si realizan clasificación:

Pueden utilizar:

- Regresión Logística

- Árboles de Decisión
- Random Forest
- SVM
- KNN

Si realizan regresión:

Pueden utilizar:

- Regresión Lineal
- Ridge
- Lasso
- KNN
- SVM
- Random Forest

Si realizan agrupación:

Pueden utilizar:

- K-Means
- DBSCAN
- Aglomerativo

5. Preparación de los datos para el modelo

No deberán repetir el EDA ni la limpieza del trabajo anterior.

Deberán utilizar el dataset que ya prepararon.

Sin embargo, podrán realizar las transformaciones que sean necesarias para poder aplicar el algoritmo seleccionado.

Por ejemplo, si alguna variable necesita ser transformada para poder trabajar con el modelo, deberán realizarla y explicar brevemente qué hicieron.

6. Split — División de los datos

Para los problemas de clasificación y regresión, deberán dividir el conjunto de datos en:

Datos de entrenamiento

Son los datos que utilizará el modelo para aprender.

Datos de prueba

Son los datos que se reservan para comprobar cómo funciona el modelo una vez entrenado.

En clase vimos que esta división corresponde a la fase **Split**.

Podrán utilizar, por ejemplo:

80 % → entrenamiento

20 % → prueba

7. Training / Fitting

Una vez realizada la división, deberán entrenar el modelo utilizando el **conjunto de entrenamiento**.

Deberán mostrar el código utilizado y explicar brevemente qué está haciendo.

Esta es la segunda fase que trabajamos en clase:

Training o Fitting → el modelo aprende utilizando los datos de entrenamiento.

8. Testing

Una vez entrenado el modelo, deberán utilizar el **conjunto de prueba** para realizar las predicciones correspondientes.

Esta es la tercera fase:

Testing → evaluar el modelo utilizando datos que fueron reservados para la prueba.

Deberán mostrar:

- las predicciones realizadas;
- los resultados obtenidos;
- una breve interpretación.

9. Análisis de los resultados

Deberán analizar el comportamiento del modelo a partir de los resultados obtenidos.

No alcanza con mostrar el resultado del código.

Deberán responder, por ejemplo:

- ¿Qué resultado obtuvo el modelo?
- ¿Las predicciones parecen razonables?
- ¿Qué diferencias observan entre los valores reales y los predichos?
- ¿Qué dificultades encontraron?
- ¿El modelo permitió responder la pregunta que se habían planteado?

Las conclusiones deben estar relacionadas con los resultados obtenidos.

10. Si realizan Clustering

En el caso de que el grupo elija un algoritmo de agrupación, el procedimiento será diferente porque estamos trabajando con **aprendizaje no supervisado**.

Deberán:

1. Seleccionar las variables.
2. Justificar su elección.
3. Elegir un algoritmo:
 - K-Means
 - DBSCAN
 - Aglomerativo.
4. Aplicar el algoritmo.
5. Visualizar los grupos obtenidos.
6. Analizar las características de los grupos.
7. Explicar qué información permiten descubrir esos grupos.

En este caso no deberán realizar Split → Training → Testing, ya que esas fases fueron presentadas en clase para la aplicación de modelos supervisados.

11. Conclusión

Finalmente deberán realizar una conclusión donde expliquen:

- qué problema plantearon;
- qué tipo de aprendizaje utilizaron;
- qué variables seleccionaron;
- qué algoritmo aplicaron;
- cómo realizaron el entrenamiento y la prueba, si corresponde;
- qué resultados obtuvieron;
- qué pudieron observar a partir del modelo.

Estructura del Colab

1. Problema a resolver

¿Qué queremos obtener con Machine Learning?

2. Tipo de aprendizaje

Clasificación / Regresión / Agrupación.

3. Variables seleccionadas

X e Y, si corresponde.

4. Preparación de los datos

Transformaciones necesarias para aplicar el modelo.

5. Algoritmo seleccionado

¿Qué algoritmo elegimos y por qué?

6. Split

Solo clasificación y regresión.

7. Training / Fitting

Solo clasificación y regresión.

8. Testing

Solo clasificación y regresión.

9. Resultados e interpretación

10. Conclusión

IMPORTANTE

El objetivo de este trabajo no es solamente ejecutar un algoritmo. Deberán demostrar que comprenden qué problema están intentando resolver, por qué eligieron determinado algoritmo y qué significan los resultados obtenidos. No es necesario utilizar varios algoritmos. La propuesta es seleccionar un algoritmo de los trabajados en clase, aplicarlo correctamente y comprender su funcionamiento y sus resultados.